

TME 1 — Estimation de densité

Objectif

Nous étudions deux méthodes d'estimation de densité : l'histogramme et la méthode à noyaux (KDE), sur des données de points d'intérêt (POI) à Paris. Nous utilisons également l'estimateur de Nadaraya–Watson pour prédire la note d'un lieu à partir de sa position.

Données et visualisation

Les données proviennent de l'API Google Places et contiennent les coordonnées GPS de différents types de POI.

Le jeu de données contient :

- 4888 bars
- 6914 restaurants
- 556 boîtes de nuit

La note moyenne des bars est ≈ 3.10 .




Figure 1: Répartition des bars et restaurants à Paris.

On observe une forte concentration dans le centre de Paris, cohérente avec l'activité commerciale et touristique.

Estimation par histogramme

L'estimateur par histogramme découpe l'espace en cellules régulières.




Figure 2: Densité estimée par histogramme pour différents nombres de cellules.

Pour un petit nombre de cellules (steps=5), la densité est trop grossière. Pour un grand nombre (steps=40), elle devient bruitée.

→ Une valeur intermédiaire est préférable.

Cette observation est confirmée quantitativement :

- meilleur steps (test) = 10 pour les bars

Vérification de la densité

On vérifie que l'intégrale de la densité est proche de 1 :

- intégrale ≈ 1.02

Cela confirme que l'estimateur est bien une densité.

Choix du nombre de cellules




Figure 3: Log-vraisemblance en fonction du nombre de cellules.

La log-vraisemblance test est maximale pour :

- steps = 10 (bars)

Cas des données rares : boîtes de nuit

Les boîtes de nuit sont moins nombreuses.

- meilleur steps = 5

→ Une discrétisation plus grossière est nécessaire pour éviter des cellules vides.

Estimation par noyaux (KDE)




Figure 4: Densité estimée par KDE pour différents σ .

Un petit σ donne une densité bruitée. Un grand σ donne une densité trop lissée.




Figure 5: Log-vraisemblance pour la KDE.

Résultats :

- meilleur σ (gaussien) = 0.003
- meilleur σ (uniforme) = 0.02

Le noyau gaussien produit une densité plus lisse que le noyau uniforme.

Régression par Nadaraya–Watson




Figure 6: Erreur quadratique moyenne selon σ .

Résultat :

- meilleur $\sigma = 0.01$
- MSE minimale ≈ 3.49

→ Petit σ : sur-apprentissage → Grand σ : sous-apprentissage

Conclusion

Le choix des hyperparamètres est crucial :

- Histogramme : nombre de cellules
- KDE : σ
- Nadaraya-Watson : σ

Les résultats illustrent le compromis biais-variance. La validation sur un ensemble de test permet de choisir un modèle qui généralise correctement.