

TME 5 – Clustering spatial des points d'intérêt parisiens

Introduction

L'objectif de ce TME est de caractériser spatialement l'espace urbain parisien à partir des points d'intérêt présents dans différentes zones. Chaque région est représentée par un profil de types de POIs, puis ces profils sont regroupés par KMeans.

Dans le jeu de données utilisé, les types de POIs sont représentés par 12 colonnes indicatrices.

Données

Le jeu de données contient **31852 POIs** répartis dans Paris.

Les types les plus fréquents sont :

- restaurant (0.287)
- clothing_store (0.172)
- bar (0.165)
- home_goods_store (0.150)
- lodging (0.147)

On observe donc une forte dominance des restaurants et commerces.




Figure 1: Répartition des points d'intérêt dans Paris.

Les points sont très concentrés dans certaines zones, notamment le centre de Paris.

Discrétisation manuelle par grille

On utilise une grille de taille **20 × 20**, soit 400 cellules, dont 392 sont non vides.




Figure 2: Clustering des cellules obtenu avec une discrétisation en grille.

Chaque cellule est décrite par la distribution moyenne des types de POIs.

Centroïdes des clusters de la grille




Figure 3: Centroïdes des clusters obtenus avec la grille.

Les profils dominants sont :

- cluster dominé par **home_goods_store + restaurant**
- cluster dominé par **clothing_store**
- cluster dominé par **restaurant pur**
- cluster dominé par **restaurant + bar**

On observe que **le type restaurant domine presque tous les clusters**, ce qui reflète sa forte présence globale.

Choix du nombre de clusters : méthode elbow




Figure 4: Courbe elbow pour le clustering des cellules de la grille.

L'inertie diminue fortement jusqu'à $K \approx 5-6$ puis ralentit.

→ Conclusion : **K = 5 ou 6** est un bon compromis.

Limites de la grille

La grille est presque entièrement remplie (98 % des cellules), mais elle reste arbitraire et ne suit pas la densité réelle des POIs.

Discrétisation automatique de l'espace

On applique KMeans directement sur les coordonnées GPS avec **100 régions**.




Figure 5: Quantization spatiale des POIs par KMeans.

Cette méthode s'adapte mieux à la densité des données.

Clustering des régions spatiales

On regroupe ensuite ces régions en **6 clusters**.




Figure 6: Clustering des régions spatiales selon les types de POIs.

Les régions contiennent entre 111 et 576 POIs, avec une moyenne de 318.




Figure 7: Centroïdes des clusters obtenus après quantization spatiale.

Les profils sont proches de ceux observés avec la grille :

- dominance de restaurant + bar
- clusters orientés commerces
- clusters plus mixtes

Choix du nombre de clusters




Figure 8: Courbe elbow pour les régions spatiales.

On observe à nouveau un coude autour de :

K = 5 ou 6

Corrélation entre types de POIs




Figure 9: Matrice de corrélation entre types de POIs.

Corrélations importantes :

- furniture_store / home_goods_store : **0.926**
- cafe / night_club : 0.595
- clothing_store / bar : **-0.522**
- clothing_store / restaurant : -0.506

→ Interprétation :

- certains types sont fortement redondants (meubles / équipement maison)
- certains types s'excluent (commerces vs bars)

Standardisation




Figure 10: Clustering obtenu après standardisation.

Après standardisation :

- inertie = 631.98 (non comparable)
- clusters plus équilibrés

→ Effet : la standardisation réduit l'impact des types dominants comme "restaurant".

Comparaison grille vs quantization spatiale

- grille :
 - simple
 - interprétable
 - mais arbitraire
- quantization :
 - adaptée à la densité
 - plus réaliste
 - plus pertinente

Conclusion

Les résultats montrent que :

- les restaurants dominent fortement la structure urbaine
- $K \approx 5-6$ est un bon choix de clustering
- la quantization spatiale donne une meilleure partition que la grille
- certaines catégories sont redondantes (corrélations fortes)

Enfin, la standardisation permet d'équilibrer les types et d'obtenir des clusters plus représentatifs.

Les figures produites permettent d'analyser :

- la structure spatiale (cartes)
- la composition (centroïdes)
- le choix de K (elbow)